AI VIET NAM
@aivietnam.edu.vn

AI VIET NAM – AI COURSE 2025

Project (Case Study): Phân cụm khách hàng dùng K-Means

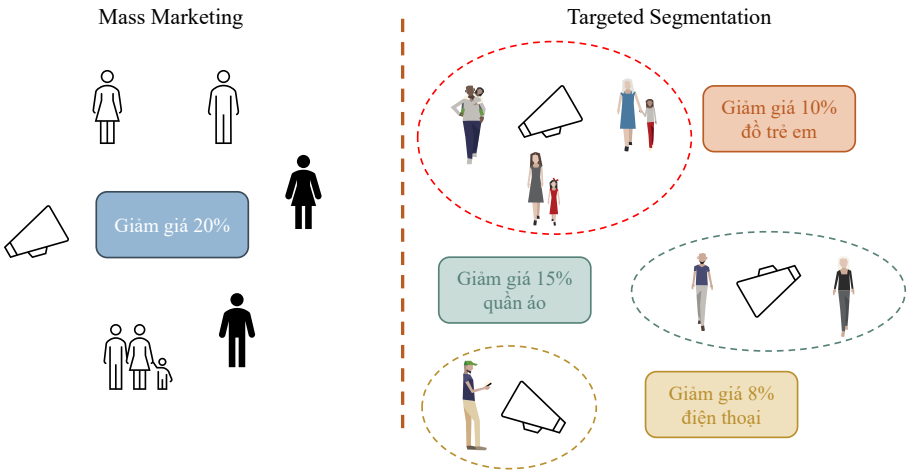
Nguyễn Thái Hà, Nguyễn Phúc Thịnh, và Nguyễn Thọ Anh Khoa

I. Phân khúc khách hàng

Trong kỷ nguyên Big Data, việc áp dụng một chiến lược kinh doanh duy nhất cho toàn bộ thị trường (hay còn gọi là mass marketing) không còn mang lại hiệu quả tối ưu. Khách hàng ngày nay mong đợi sự cá nhân hóa trong trải nghiệm mua sắm và dịch vụ. Đây là lúc bài toán "Customer Segmentation" (tạm dịch: phân khúc khách hàng) trở nên cấp thiết.

Phân khúc khách hàng là quá trình chia cơ sở khách hàng thành các nhóm nhỏ dựa trên những đặc điểm tương đồng như hành vi mua sắm, nhân khẩu học, hoặc tần suất chi tiêu. Mục tiêu cốt lõi của việc này bao gồm:

- **Tối ưu hóa Marketing (Targeted Marketing):** Thay vì gửi một email quảng cáo cho tất cả, doanh nghiệp có thể gửi khuyến mãi "đồ mẹ và bé" cho nhóm khách hàng là phụ huynh, hoặc "thiết bị công nghệ" cho nhóm khách hàng trẻ yêu thích kỹ thuật số.
- **Giữ chân khách hàng (Customer Retention):** Nhận diện nhóm khách hàng có nguy cơ rời bỏ (Churn rate cao) để có chính sách chăm sóc đặc biệt.
- **Phân bổ nguồn lực:** Tập trung ngân sách vào nhóm khách hàng mang lại giá trị lợi nhuận cao nhất (nhóm VIP).



Hình 1: Sự chuyển dịch từ tiếp thị đại trà kém hiệu quả sang phân khúc mục tiêu được cá nhân hóa.

Để thực hiện việc phân loại này một cách tự động và chính xác trên tập dữ liệu lớn, chúng ta không thể thực hiện thủ công. Ta cần sự hỗ trợ của các thuật toán Machine Learning, cụ thể là nhóm thuật toán học không giám sát (Unsupervised Learning).

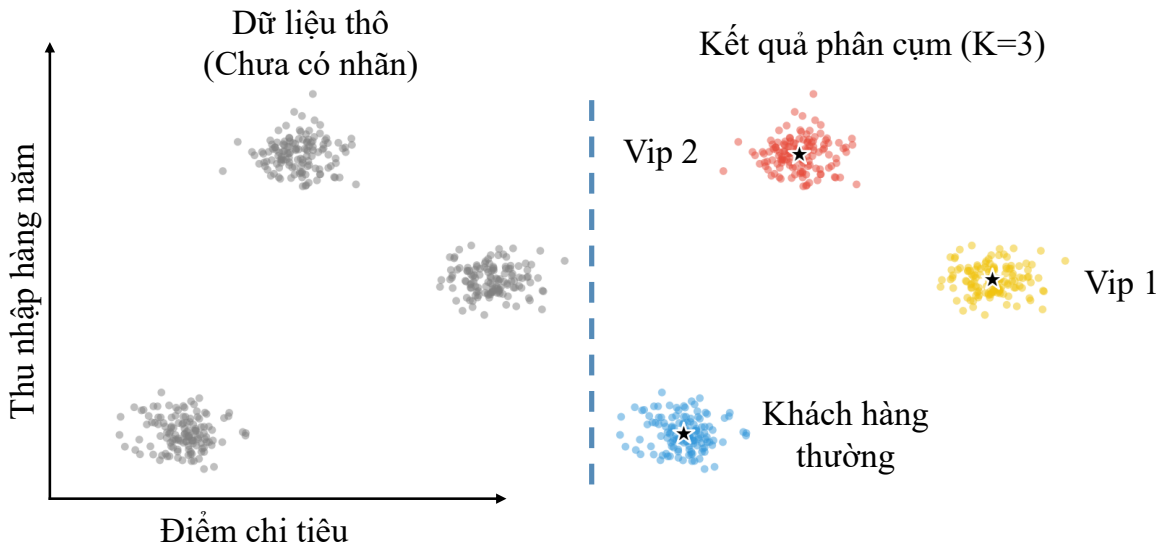
Trong dự án này, chúng ta sẽ sử dụng **K-Means Clustering** (Phân cụm K-Means) - một trong những thuật toán phổ biến và hiệu quả nhất để giải quyết bài toán phân nhóm dữ liệu chưa được dán nhãn.

Tiêu chí	**Phân loại thủ công**	**K-Means Clustering**
Độ phức tạp	Khó xử lý nhiều chiều dữ liệu cùng lúc.	Xử lý tốt đa chiều (Tuổi, Thu nhập, Tần suất mua...).
Tính khách quan	Dễ bị ảnh hưởng bởi cảm tính người phân loại.	Dựa hoàn toàn vào khoảng cách toán học giữa các điểm dữ liệu.
Khả năng mở rộng	Tốn thời gian khi dữ liệu lớn.	Tốc độ xử lý nhanh, phù hợp với Big Data.

Bảng 1: So sánh hiệu quả giữa phân loại thủ công và thuật toán K-Means.

Trong bài học này, chúng ta sẽ đóng vai là một Data Scientist cho một chuỗi bán lẻ. Nhiệm vụ của chúng ta là phân tích dữ liệu giao dịch và xây dựng mô hình K-Means để nhóm khách hàng. Các bước thực hiện bao gồm:

1. **Khám phá dữ liệu (EDA):** Hiểu cấu trúc và phân bố của tập dữ liệu.
2. **Tiền xử lý:** Chuẩn hóa dữ liệu để đảm bảo thuật toán hoạt động chính xác.
3. **Lựa chọn số cụm K tối ưu:** Sử dụng phương pháp Elbow Method hoặc Silhouette score để tìm K tốt nhất.
4. **Huấn luyện mô hình:** Khởi tạo và huấn luyện K-Means.
5. **Phân tích kết quả:** Trực quan hóa các cụm và đưa ra đề xuất kinh doanh (Actionable Insights).



Hình 2: Trực quan hóa cách K-Means nhóm các điểm dữ liệu thô (trái) thành các cụm có tâm xác định (phải).

Danh sách các module trong project. Để tiện theo dõi, bảng dưới đây tổng hợp các phần chính trong module của chúng ta. Toàn bộ dự án được chứa trong link Github này.

Bảng thành phần Project

Thành phần	Ý nghĩa và chức năng
`src/clustering_library.py`	Thư viện trung tâm của dự án, chứa các lớp (class) xử lý chính: `DataCleaner` (làm sạch dữ liệu), `FeatureEngineer` (tạo đặc trưng khách hàng), `ClusterAnalyzer` (thực hiện phân cụm K-Means) và `DataVisualizer` (trực quan hóa).
`notebooks/01_cleaning_and_ed`	Notebook bước 1: Thực hiện tải dữ liệu thô, xử lý các giá trị thiếu, lọc dữ liệu rác (đơn hàng bị hủy) và thực hiện phân tích khám phá dữ liệu (EDA) để hiểu tổng quan về tập dữ liệu.
`notebooks/02_feature_enginee`	Notebook bước 2: Chịu trách nhiệm tạo ra 16 đặc trưng (features) hành vi khách hàng từ dữ liệu giao dịch, thực hiện biến đổi Box-Cox để chuẩn hóa phân phối và Scaling dữ liệu.
`notebooks/03_modeling.ipynb`	Notebook bước 3: Tìm số cụm tối ưu (sử dụng Elbow Method và Silhouette Score), huấn luyện mô hình K-Means, và phân tích đặc điểm của từng nhóm khách hàng được tạo ra.
`data/`	Thư mục chứa dữ liệu đầu vào (`online_retail.csv`) và lưu trữ các dữ liệu trung gian đã qua xử lý (processed data) để sử dụng giữa các bước phân tích.
`setup_code.py`	Script hỗ trợ khởi tạo cấu trúc thư mục chuẩn cho dự án, tạo các file cấu hình ban đầu và cài đặt môi trường cần thiết.

Mục lục

I. Phân khúc khách hàng **1**

II. Phân tích và làm sạch dữ liệu **6**

II.1. Tải và kiểm tra dữ liệu ban đầu 6

II.2. Làm sạch dữ liệu 7

II.3. EDA 7

III. Tạo đặc trưng **12**

III.1. Tại sao cần mở rộng Features? 12

III.2. Xây dựng bộ đặc trưng 12

III.3. Chuẩn hóa và biến đổi Dữ liệu 14

IV. Mô hình hóa và phân cụm **17**

IV.1. Giới thiệu về K-Means clustering 17

IV.2. Xác định số cụm tối ưu 17

IV.3. Phân tích thành phần chính (PCA) 18

IV.4. So sánh phân cụm K=3 và K=4 18

IV.5. Phân tích chuyên sâu biểu đồ Radar 20

IV.6. Quy trình định danh khách hàng với ChatGPT 22

V. Các hướng cải tiến **23**

VI. Câu hỏi trắc nghiệm **25**

VII. Tài liệu tham khảo **27**

Phụ lục **27**

II. Phân tích và làm sạch dữ liệu

Trong bất kỳ dự án nào, việc hiểu và làm sạch dữ liệu là bước nền tảng quan trọng nhất. Dữ liệu thực tế thường chứa nhiễu, giá trị thiếu hoặc các ngoại lệ (outliers) có thể làm sai lệch kết quả của mô hình phân cụm. Trong phần này, ta sẽ sử dụng bộ dữ liệu *Online Retail* để thực hiện quy trình từ làm sạch đến phân tích khám phá (Exploratory Data Analysis - EDA).

Tại sao chúng ta dùng OOP?

Để đảm bảo tính chuyên nghiệp khi trình bày cho người nghe, dự án này áp dụng tư duy Lập trình hướng đối tượng (OOP). Thay vì viết hàng trăm dòng script xử lý rồi rắm vào chính những file notebook mà chúng ta trình bày, chúng ta đóng gói logic vào các lớp (Class) trong một file riêng. Sau đó, khi làm việc với notebook ta có, ta sẽ sử dụng hàm `import` để sử dụng các lớp nói trên. Điều này giúp notebook sạch sẽ, tập trung vào kết quả và dễ dàng tái sử dụng.
Ví dụ minh họa sự tinh gọn:

```
from clustering_library import DataCleaner, DataVisualizer

# Code ngắn gọn, dễ hiểu cho người đọc
cleaner = DataCleaner(file_path='online_retail.csv')
df_uk = cleaner.clean_data()
```

Tiếp theo, chúng ta sẽ sử dụng class `DataCleaner` này để xử lý tập dữ liệu *Online Retail*, bao gồm việc loại bỏ các hóa đơn hủy và lọc khách hàng UK.

II.1. Tải và kiểm tra dữ liệu ban đầu

Đầu tiên, ta cần tải dữ liệu và kiểm tra cấu trúc cơ bản. Bộ dữ liệu bao gồm các giao dịch từ tháng 12/2010 đến tháng 12/2011 của một doanh nghiệp bán lẻ trực tuyến tại Anh.

Ta sử dụng lớp `DataCleaner` từ thư viện `clustering_library` để quản lý việc tải dữ liệu:

Tải dữ liệu

```
from clustering_library import DataCleaner, DataVisualizer

# Khởi tạo và tải dữ liệu
data_path = "../data/raw/online_retail.csv"
cleaner = DataCleaner(data_path)
df = cleaner.load_data()

# Kiểm tra thông tin cơ bản
print(f"Kích thước: {df.shape}")
print(f"Số lượng khách hàng: {df['CustomerID'].nunique()}")
```

Dữ liệu thô ban đầu chứa hơn 500,000 dòng, tuy nhiên bao gồm cả các giao dịch bị hủy, dữ liệu thiếu thông tin khách hàng và các giao dịch từ nhiều quốc gia khác nhau.

II.2. Làm sạch dữ liệu

Để đảm bảo tính nhất quán cho việc phân khúc khách hàng, ta thực hiện các bước làm sạch sau:

1. **Tính toán tổng giá trị:** Tạo cột `TotalPrice` = `Quantity` × `UnitPrice`.
2. **Xử lý đơn hàng hủy:** Loại bỏ các hóa đơn bắt đầu bằng ký tự 'C' (Cancelled).
3. **Lọc theo địa lý:** Chỉ giữ lại các giao dịch tại **United Kingdom** để tránh nhiễu do sự khác biệt về hành vi mua sắm giữa các quốc gia.
4. **Xử lý dữ liệu thiếu:** Loại bỏ các bản ghi không có `CustomerID` vì ta cần định danh khách hàng để phân cụm.
5. **Làm sạch giá trị:** Loại bỏ các giao dịch có số lượng hoặc đơn giá âm/bằng 0.

Thực hiện làm sạch dữ liệu

```
# Thực hiện quy trình làm sạch
df_uk = cleaner.clean_data()

# Tạo thêm các đặc trưng thời gian (Giờ, Ngày trong tuần)
cleaner.create_time_features()

print(f"Số lượng giao dịch sau khi làm sạch: {len(df_uk)}")
```

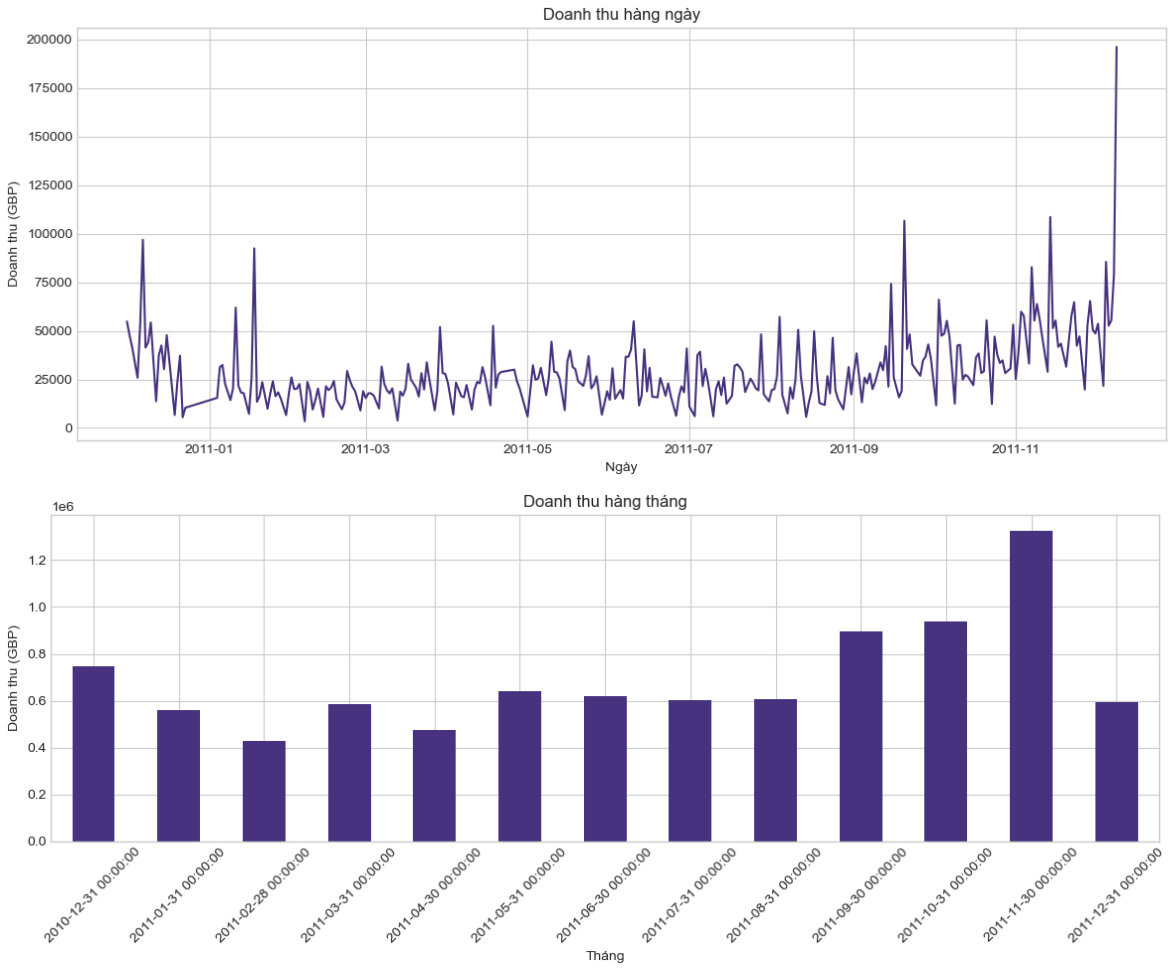
Sau quá trình này, ta thu được bộ dữ liệu sạch, sẵn sàng cho việc phân tích sâu hơn.

II.3. EDA

Sau khi có được bộ dữ liệu đã được làm sạch, sau đây chúng ta sẽ thực hiện việc nghiên cứu bộ dữ liệu này qua phương pháp trực quan hóa. Các bạn muốn tìm hiểu về cách vẽ nên các chart như dưới đây có thể xem thêm ở file `src/clustering_library.py` và lớp `DataVisualizer` trong dự án.

II.3.1. Doanh thu theo thời gian

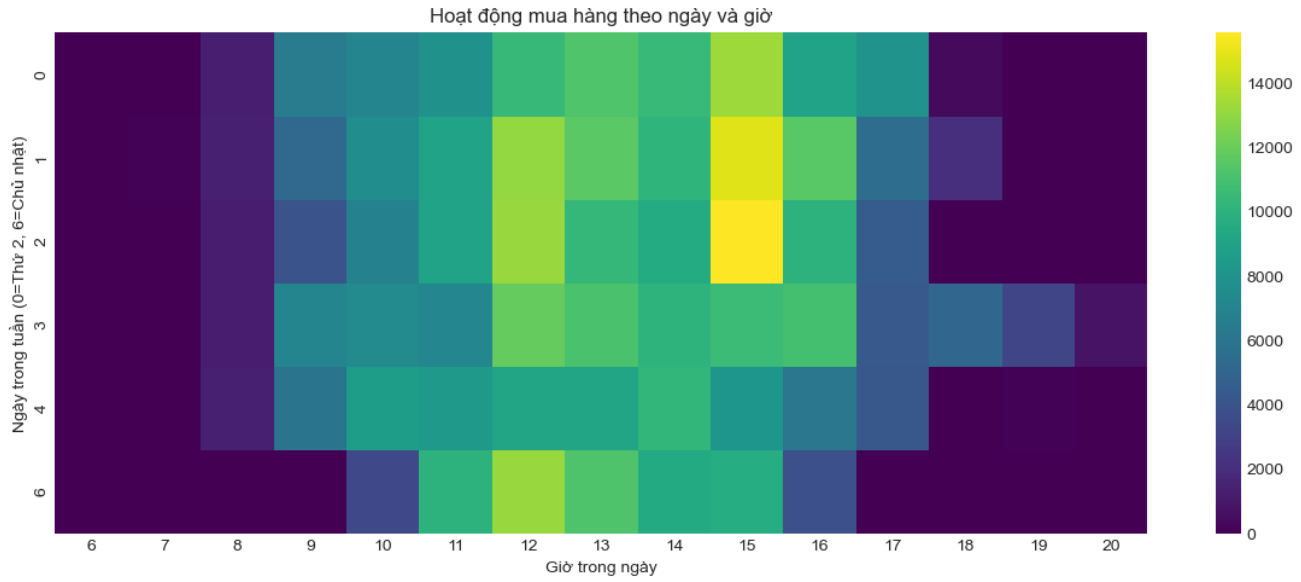
Trước tiên, việc hiểu rõ xu hướng doanh thu giúp ta nhận diện tính mùa vụ và sức khỏe chung của doanh nghiệp. Biểu đồ dưới đây thể hiện doanh thu theo ngày và theo tháng.



Hình 3: Biểu đồ xu hướng doanh thu theo ngày và tháng. Ta có thể quan sát thấy sự biến động doanh thu và các đỉnh điểm mua sắm vào dịp cuối năm.

II.3.2. Hành vi mua sắm

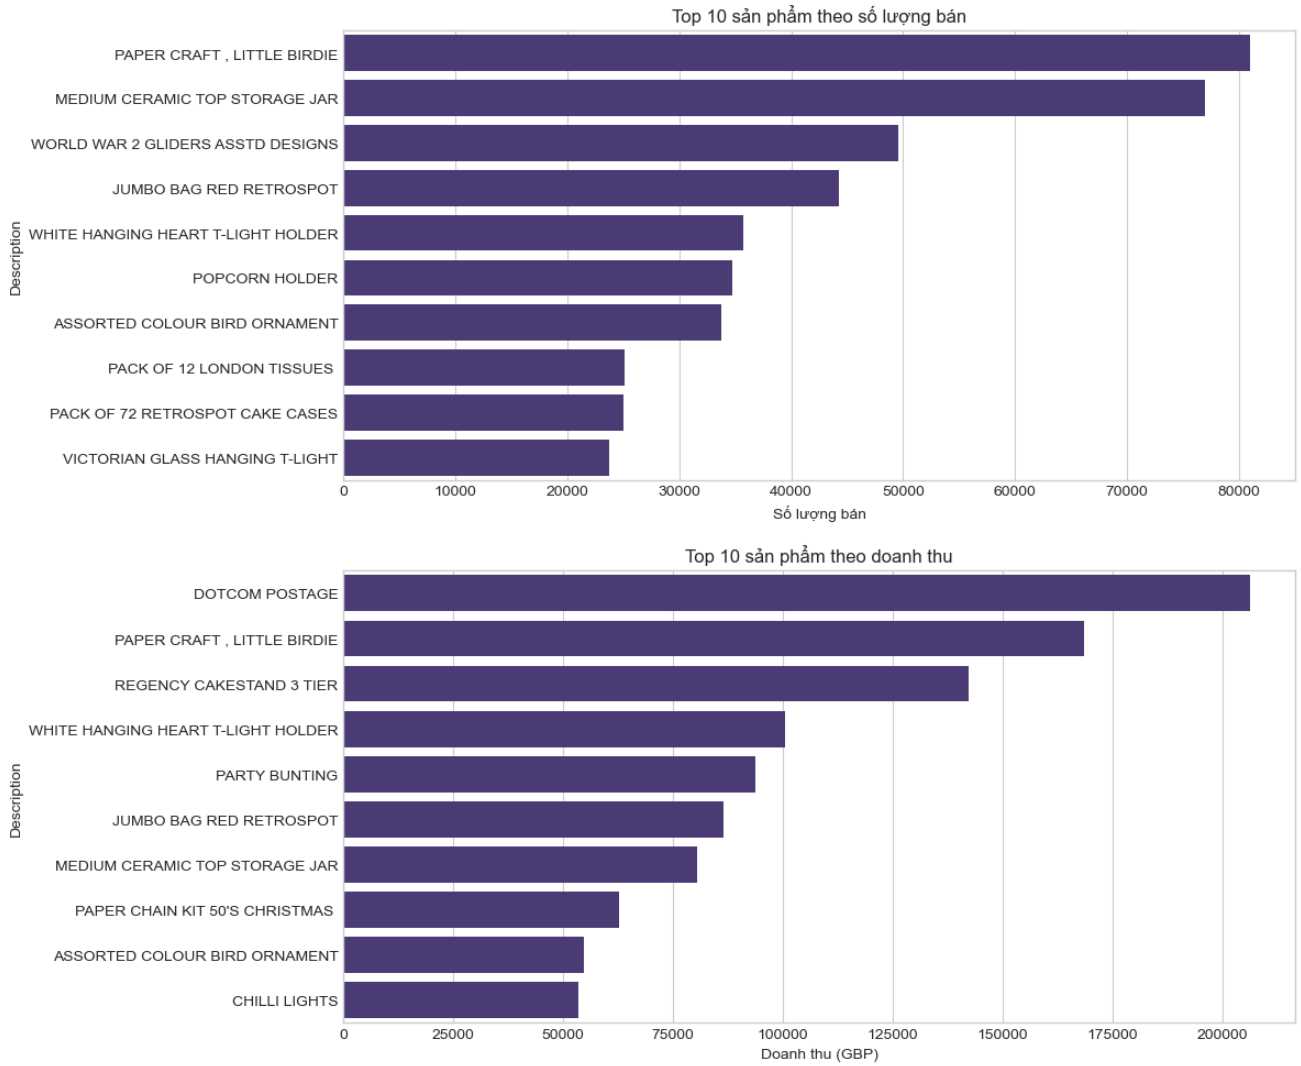
Để tối ưu hóa các chiến dịch marketing, ta cần biết khách hàng thường mua sắm vào khung giờ nào trong ngày và ngày nào trong tuần.



Hình 4: Heatmap thể hiện tần suất mua hàng theo "giờ" trong ngày và "ngày" trong tuần. Vùng màu sáng hơn thể hiện mật độ giao dịch cao hơn. Khách hàng của chúng ta thường mua vào giờ hành chính.

II.3.3. Phân tích sản phẩm và khách hàng

Ta cũng cần xem xét các sản phẩm bán chạy nhất và phân phối chi tiêu của khách hàng để có cái nhìn tổng quan về danh mục sản phẩm hay còn gọi là product portfolio.



Hình 5: Top 10 sản phẩm bán chạy nhất theo số lượng và doanh thu. Các sản phẩm này thường là các mặt hàng trang trí hoặc quà tặng phổ biến.

II.3.4. Phân tích RFM (Recency - Frequency - Monetary)

Và cuối cùng, trước khi đi vào các kỹ thuật phân cụm phức tạp, ta xem xét phân phối của ba chỉ số cơ bản RFM. Đây không chỉ là các con số thống kê, mà là ba trụ cột giúp trả lời các câu hỏi chiến lược về hành vi khách hàng:

- **Recency (sự mới mẻ):** Số ngày kể từ lần mua cuối cùng.
  → *Ý nghĩa:* Đo lường **mức độ gắn kết**. Khách hàng mới mua gần đây có xác suất quay lại cao hơn, trong khi Recency cao báo hiệu nguy cơ rời bỏ.

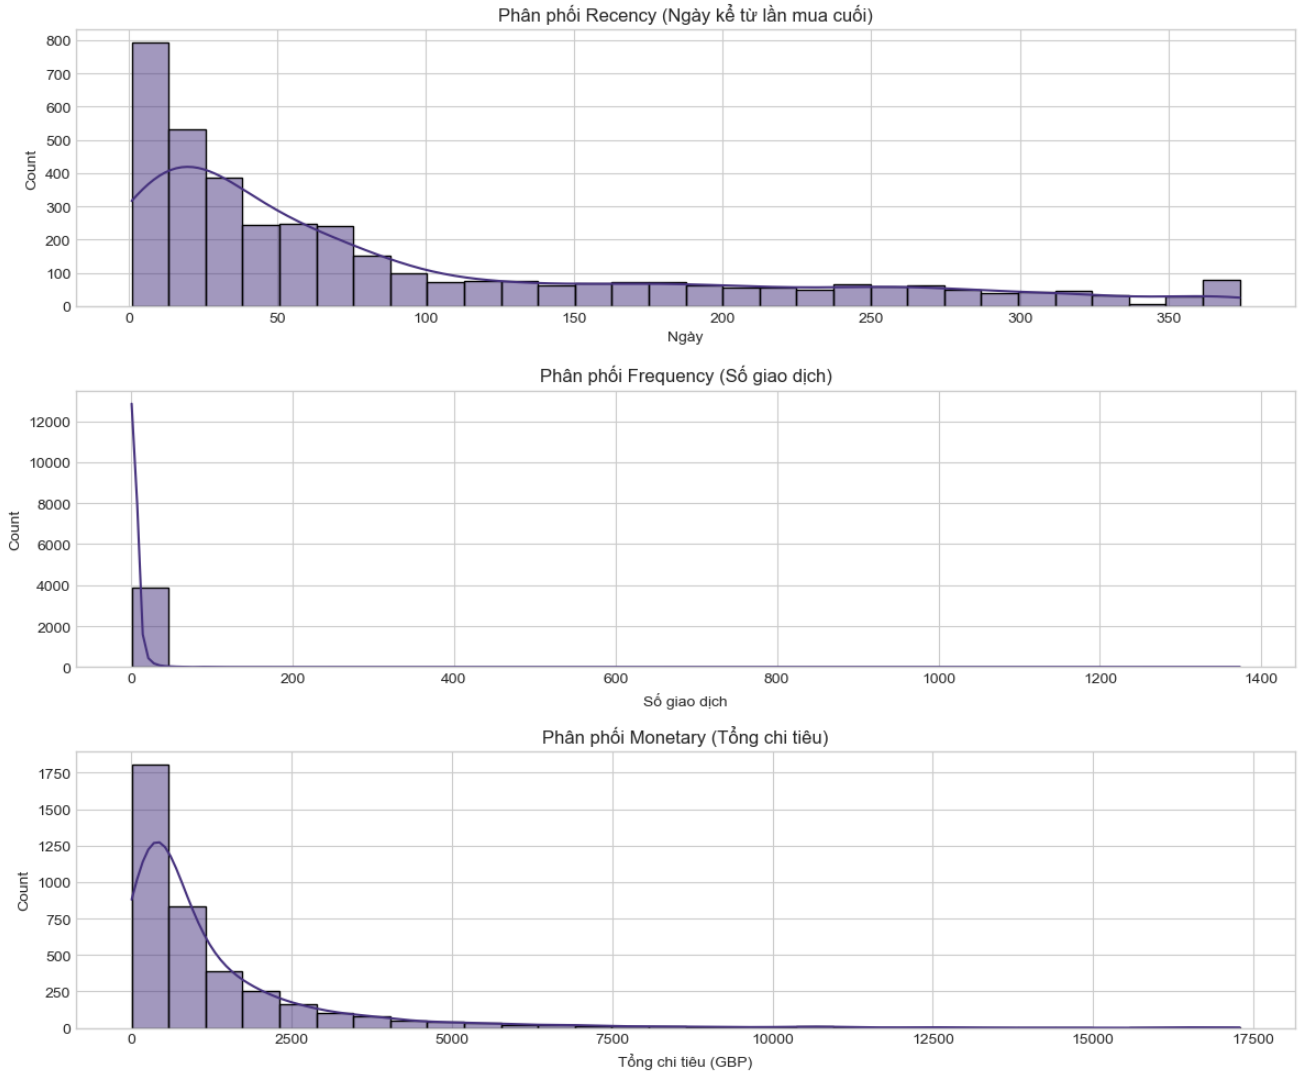
- **Frequency (tần suất):** Tổng số đơn hàng đã thực hiện.
  → *Ý nghĩa:* Đo lường **độ trung thành**. Giúp phân biệt giữa khách vãng lai và khách hàng thân thiết có thói quen mua sắm định kỳ.

- **Monetary (giá trị tiền tệ):** Tổng số tiền khách hàng đã chi tiêu.
  → *Ý nghĩa:* Đo lường **giá trị trọn đời**. Giúp nhận diện nhóm "Cá mập" - những người

đóng góp phần lớn doanh thu theo nguyên lý Pareto (80/20).

Tính toán chỉ số RFM

```
# Tính toán RFM
rfm_data = cleaner.calculate_rfm()
visualizer.plot_rfm_analysis(rfm_data)
```



Hình 6: Phân phối của các chỉ số Recency, Frequency và Monetary. Đồ thị cho thấy sự phân phối lệch (skewed), đặc trưng của dữ liệu bán lẻ (quy luật 80/20).

Sau quá trình làm sạch và EDA, ta đã có một bộ dữ liệu chất lượng cao từ thị trường UK. Các phân tích ban đầu cho thấy sự đa dạng lớn trong hành vi khách hàng, từ những người mua sắm thường xuyên đến những khách hàng vãng lai. Đây là tiền đề vững chắc để ta bước sang giai đoạn tiếp theo: Feature Engineering (tạm dịch: tạo thêm đặc trưng) để xây dựng các biến số đầu vào cho mô hình K-Means.

Tổng quan bước 1

Trong phần này, chúng ta đã hoàn tất quy trình chuẩn bị dữ liệu từ tập dữ liệu Online Retail thô. Sau khi tiền xử lý, ta tinh lọc được một bộ dữ liệu chất lượng cao gồm **354,321** giao dịch từ **3,920** khách hàng duy nhất trong giai đoạn từ tháng 12/2010 đến tháng 12/2011.
Quá trình EDA đã cho ta thấy những xu hướng quan trọng: doanh thu toàn cục có xu hướng tăng trưởng tích cực theo thời gian và hoạt động mua sắm tập trung chủ yếu vào khung giờ hành chính các ngày trong tuần. Đặc biệt, việc phân tích sơ bộ chỉ số **RFM** (Recency, Frequency, Monetary) cho thấy sự đa dạng lớn trong tần suất và giá trị chi tiêu của từng cá nhân.

III. Tạo đặc trưng

Sau khi làm sạch dữ liệu, bước tiếp theo là chuyển đổi dữ liệu giao dịch thô thành các đặc trưng có ý nghĩa ở cấp độ khách hàng. Thay vì chỉ sử dụng mô hình RFM truyền thống (3 biến), ta sẽ xây dựng một bộ 16 đặc trưng toàn diện để nắm bắt đa chiều hành vi mua sắm của người dùng.

III.1. Tại sao cần mở rộng Features?

Mô hình RFM (Recency, Frequency, Monetary) là tiêu chuẩn trong việc phân khúc khách hàng, nhưng nó có những hạn chế nhất định:

- **Thiếu chiều sâu về sản phẩm:** RFM không cho biết khách hàng mua đa dạng sản phẩm hay chỉ tập trung vào một vài mặt hàng.
- **Bỏ qua hành vi trong từng giao dịch:** RFM chỉ nhìn vào tổng thể, không phản ánh thói quen chi tiêu trong mỗi lần mua (ví dụ: mua ít nhưng giá trị cao vs mua nhiều nhưng giá trị thấp).
- **Độ nhạy với giá:** RFM không tách biệt rõ ràng giữa khách hàng mua hàng giá rẻ số lượng lớn và khách hàng mua hàng cao cấp số lượng ít.

Do đó, ta xây dựng bộ 16 features chia làm 4 nhóm chính để khắc phục các hạn chế trên.

III.2. Xây dựng bộ đặc trưng

Ta sử dụng lớp `FeatureEngineer` để tự động hóa quá trình này.

Khởi tạo Feature Engineering

```
from clustering_library import FeatureEngineer

# Tải dữ liệu đã làm sạch
data_path = '../data/processed/cleaned_uk_data.csv'
engineer = FeatureEngineer(data_path)
```

```
df = engineer.load_data()

# Tạo features
customer_features = engineer.create_customer_features()
```

Dưới đây là chi tiết ý nghĩa của 4 nhóm đặc trưng được tạo thêm. Để đọc đầy đủ ý nghĩa của từng thuộc tính một trong 16 thuộc tính, bạn có thể tham khảo file `notebooks/-02_feature_engineering.ipynb`:

III.2.1. Nhóm 1: Chỉ số cơ bản (Volume & Value)

Nhóm này mở rộng từ dữ liệu RFM, cung cấp cái nhìn tổng quan về quy mô tiêu dùng.

- `Sum_Quantity`: Tổng số lượng sản phẩm đã mua.
- `Mean_UnitPrice`: Mức giá trung bình của các sản phẩm khách hàng chọn (độ nhạy về giá).
- `Sum_TotalPrice`: Tổng chi tiêu trọn đời (tương đương Monetary).
- `Count_Invoice`: Số lần mua hàng (tương đương Frequency).
- `Count_Stock`: Số lượng mã sản phẩm khác nhau đã mua (độ đa dạng).

III.2.2. Nhóm 2: Hành vi theo Giao dịch (Transaction Behavior)

Nhóm này trả lời câu hỏi: "Mỗi lần vào cửa hàng, khách hàng cư xử thế nào?"

- `Mean_QuantitySumPerInvoice`: Giỏ hàng trung bình to hay nhỏ?
- `Mean_TotalPriceSumPerInvoice`: Giá trị trung bình mỗi hóa đơn.
- `Mean_StockCountPerInvoice`: Trung bình mỗi lần mua bao nhiêu loại hàng?

III.2.3. Nhóm 3 & 4: Hành vi theo Sản phẩm (Product Preference)

Nhóm này đi sâu vào sở thích sản phẩm cụ thể.

- `Mean_InvoiceCountPerStock`: Trung bình một sản phẩm được mua lại bao nhiêu lần (độ trung thành với sản phẩm).
- `Mean_UnitPriceMeanPerStock`: Giá trị trung bình của từng dòng sản phẩm khách hàng chọn.

III.3. Chuẩn hóa và biến đổi Dữ liệu

Quan sát trực quan dữ liệu gốc qua biểu đồ Histogram và Boxplot (hình dưới), ta nhận thấy một vấn đề nghiêm trọng: dữ liệu khách hàng bị lệch phải (right-skewness). Hầu hết dữ liệu tập trung ở giá trị thấp (ví dụ: số lượng mua ít), nhưng có một "đuôi dài" các giá trị cực lớn kéo về phía bên phải.

Thay vì chỉ sử dụng Logarit thông thường, ta áp dụng phép biến đổi Box-Cox ở đây. Đây là kỹ thuật tìm ra tham số λ tối ưu để biến đổi dữ liệu về dạng gần với phân phối chuẩn (Gaussian) nhất có thể, giúp:

1. Co ngắn khoảng cách của các giá trị ngoại lai (xử lý đuôi dài).
2. Ổn định phương sai.
3. Tạo ra không gian dữ liệu đối xứng hơn cho K-Means hoạt động hiệu quả.

III.3.1. Box-Cox Transformation

Code cho thuật toán Box-Cox được trình bày như dưới đây. Trước hết, 'CustomerID' được tách ra làm index để không bị biến đổi nhầm, tránh gây nhiễu mô hình. Tiếp theo, dữ liệu được cộng thêm 1 ($x + 1$) để xử lý các giá trị bằng 0 (do toán học của Box-Cox yêu cầu đầu vào dương tuyệt đối). Cuối cùng, hàm 'boxcox' được áp dụng lần lượt lên từng đặc trưng để tự động tìm ra tham số λ tối ưu riêng biệt, giúp đưa biểu đồ phân phối của các chỉ số RFM từ dạng lệch (skewed) về dạng hình chuông (Gaussian).

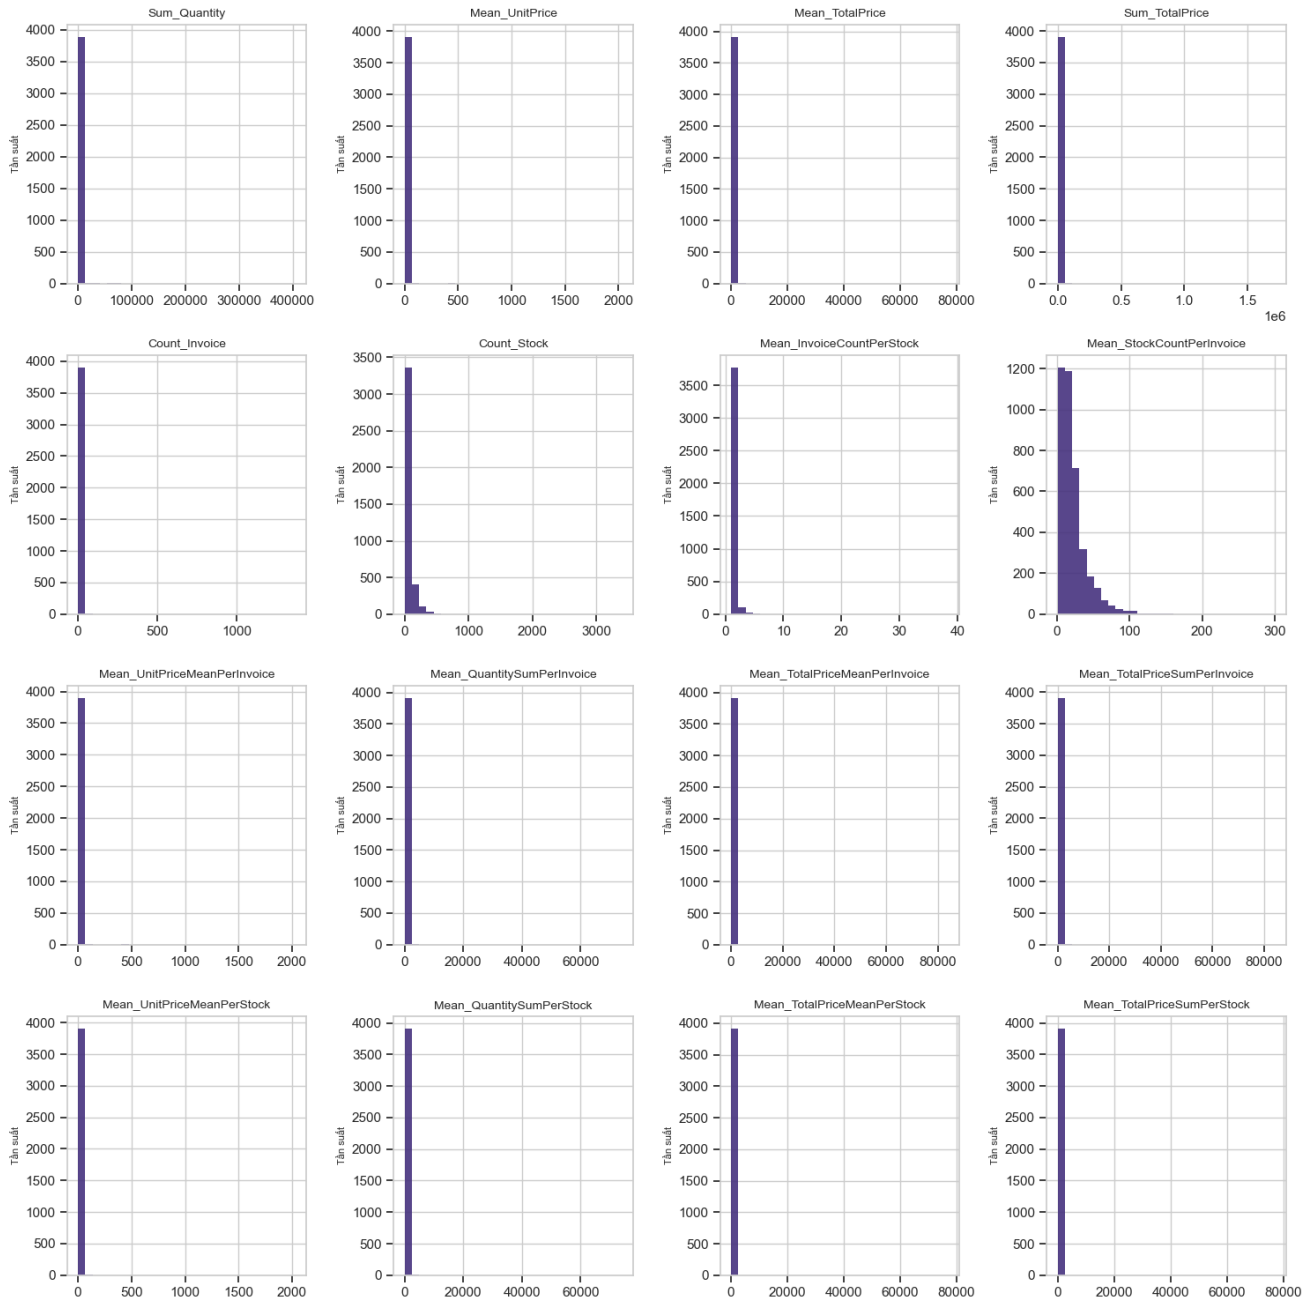
Định nghĩa hàm Box-Cox

```python
def transform_features(self):
    # Set CustomerID as index
    customer_features_indexed = self.customer_features.set_index("CustomerID")

    # Apply Box-Cox transformation
    feature_values = customer_features_indexed.values + 1
    self.customer_features_transformed = customer_features_indexed.copy()

    for i, feature in enumerate(self.feature_customer):
        transformed, lambda_param = boxcox(feature_values[:, i])
        self.customer_features_transformed.iloc[:, i] = transformed

    return self.customer_features_transformed
```

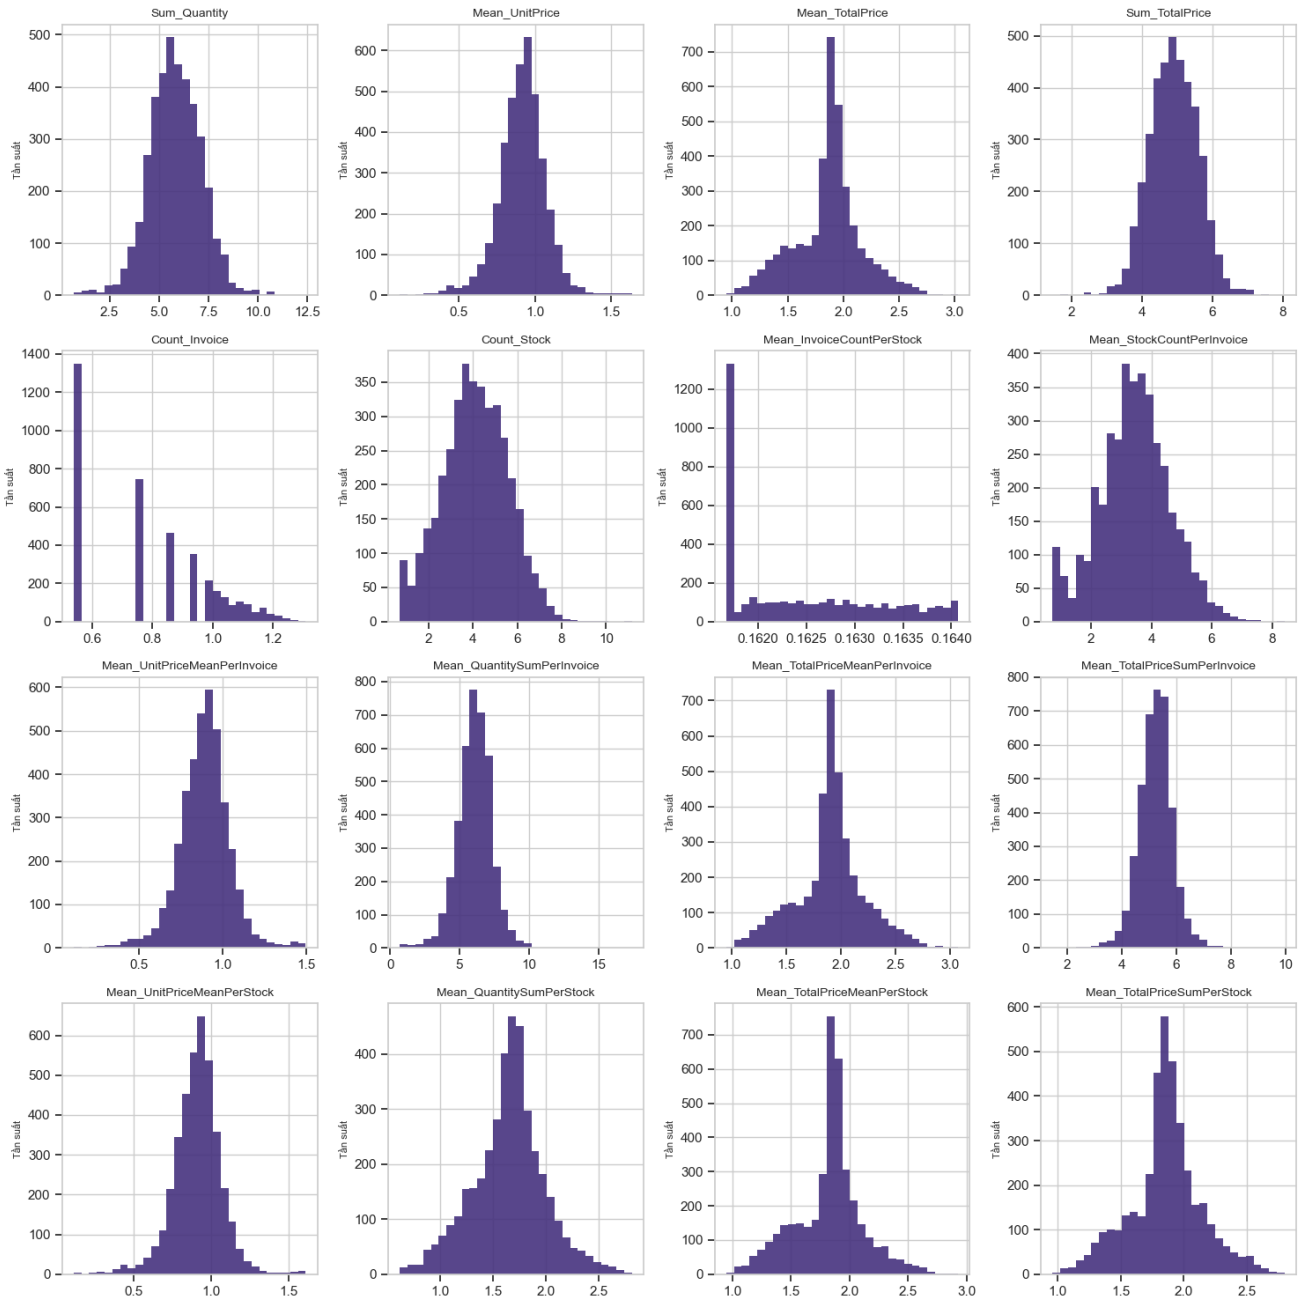


Hình 7: Phân phối của các features trước khi biến đổi. Ta thấy rõ sự lệch phải của dữ liệu.

Sử dụng hàm Box-Cox

```
# Áp dụng Box-Cox transformation
customer_features_transformed = engineer.transform_features()

# Trực quan hóa sau khi biến đổi
engineer.plot_features_histograms(transformed=True)
```



Hình 8: Phân phối của các features sau khi áp dụng Box-Cox. Dữ liệu đã trở nên đối xứng hơn, phù hợp cho K-Means.

III.3.2. Standard Scaling

Cuối cùng, ta đưa tất cả features về cùng một thang đo (mean=0, std=1) để đảm bảo không có feature nào lấn át các feature khác do đơn vị lớn hơn (ví dụ: Doanh thu hàng nghìn bảng vs Số lần mua hàng chục lần).

Standard Scaling

```
# Chuẩn hóa dữ liệu (Z-score normalization)
customer_features_scaled = engineer.scale_features()
engineer.save_features()
```

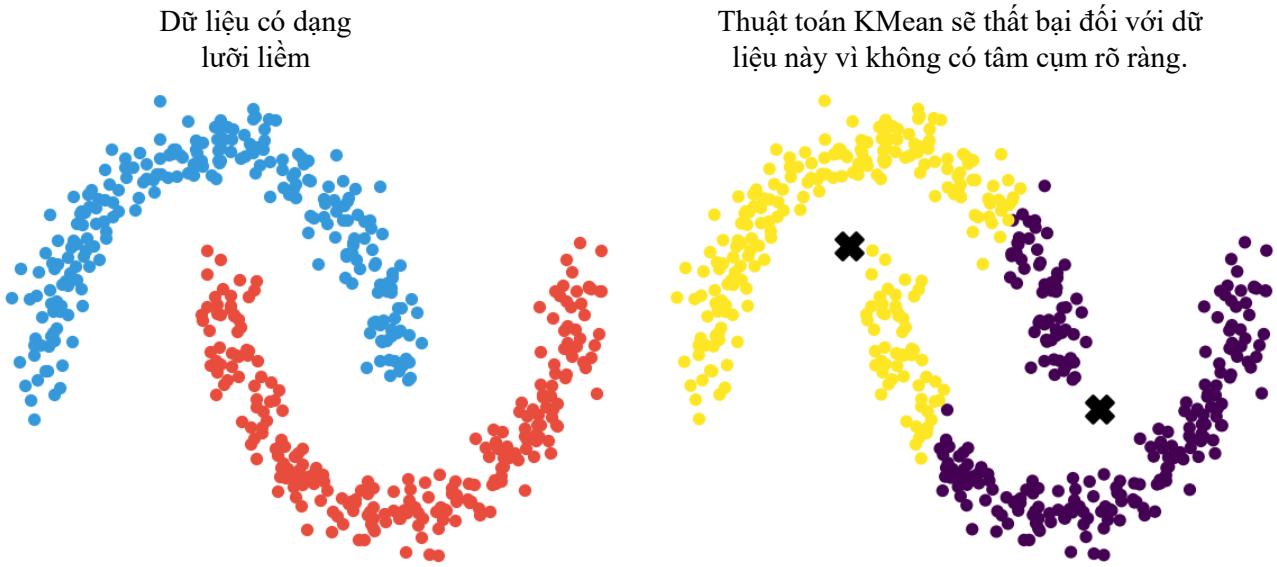
IV. Mô hình hóa và phân cụm

Sau khi đã có bộ dữ liệu đặc trưng chất lượng cao, ta tiến hành bước quan trọng nhất: Phân nhóm khách hàng sử dụng thuật toán học máy không giám sát. Trong dự án này, ta sử dụng thuật toán K-Means clustering.

IV.1. Giới thiệu về K-Means clustering

K-Means là một trong những thuật toán phân cụm phổ biến nhất nhờ sự đơn giản và hiệu quả. Mục tiêu của K-Means là chia N điểm dữ liệu thành K cụm sao cho khoảng cách giữa các điểm trong cùng một cụm là nhỏ nhất.

Để hiểu rõ hơn về cơ chế hoạt động và ứng dụng thực tế của K-Means, bạn có thể tham khảo bài viết chi tiết tại đây.

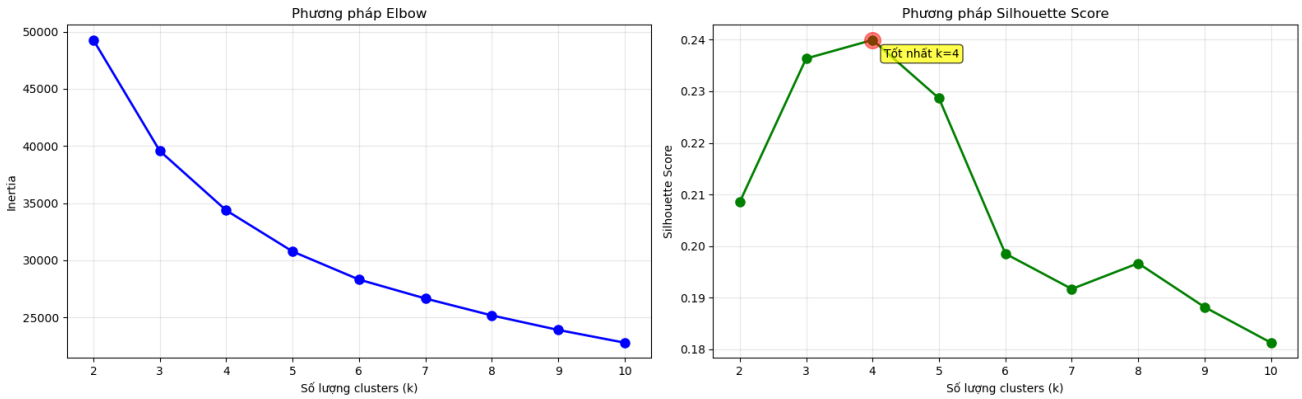


Hình 9: Minh họa điểm yếu của K-Means với dữ liệu không có dạng hình cầu. Thuật toán thất bại trong việc phân tách hai cụm hình lưỡi liềm do dựa trên khoảng cách Euclidean.

IV.2. Xác định số cụm tối ưu

Việc chọn số lượng cụm K phù hợp là bài toán mà ta cân bằng giữa độ chính xác và khả năng diễn giải các cụm đó. Để lựa chọn số lượng K phù hợp, ta sử dụng kết hợp hai phương pháp chính. Đầu tiên là "Elbow method", giúp tìm điểm "khuỷu tay" nơi việc tăng thêm cụm không

làm giảm đáng kể phương sai nội cụm. Phương pháp thứ hai là "Silhouette score", dùng để đo lường độ tách biệt giữa các cụm, với giá trị càng gần 1 càng tốt.



Hình 10: Biểu đồ Elbow và Silhouette score. Dựa trên biểu đồ, ta thấy K=3 hoặc K=4 là các lựa chọn tối ưu.

IV.3. Phân tích thành phần chính (PCA)

Trước khi phân cụm, ta sử dụng PCA để giảm chiều dữ liệu, giúp trực quan hóa dữ liệu nhiều chiều (16 chiều) xuống còn 2 hoặc 3 chiều để dễ quan sát cấu trúc phân bố.

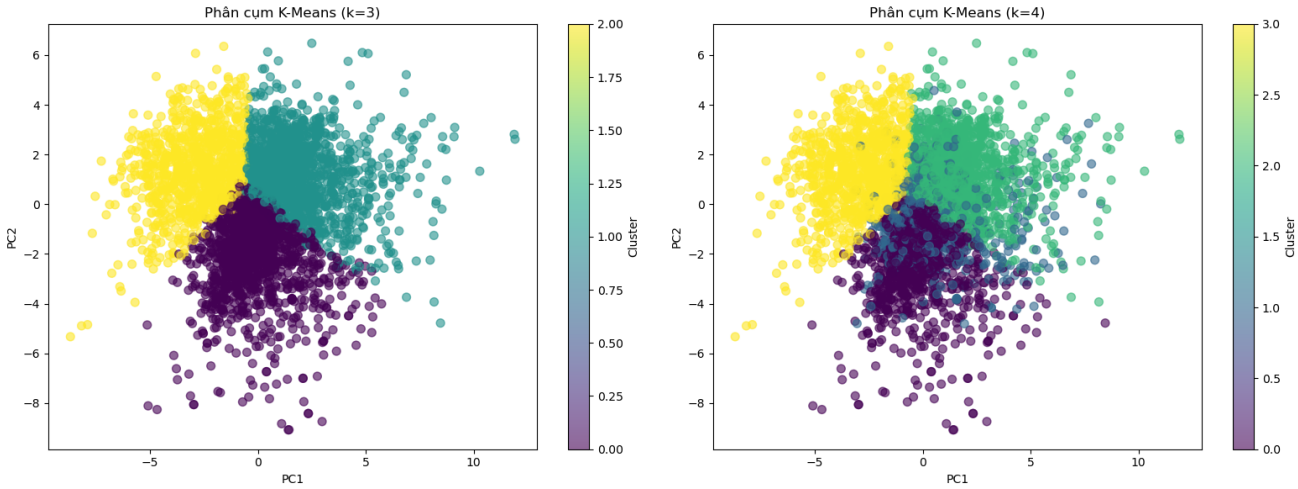
Thực hiện PCA

```
# Áp dụng PCA
df_pca = analyzer.apply_pca()

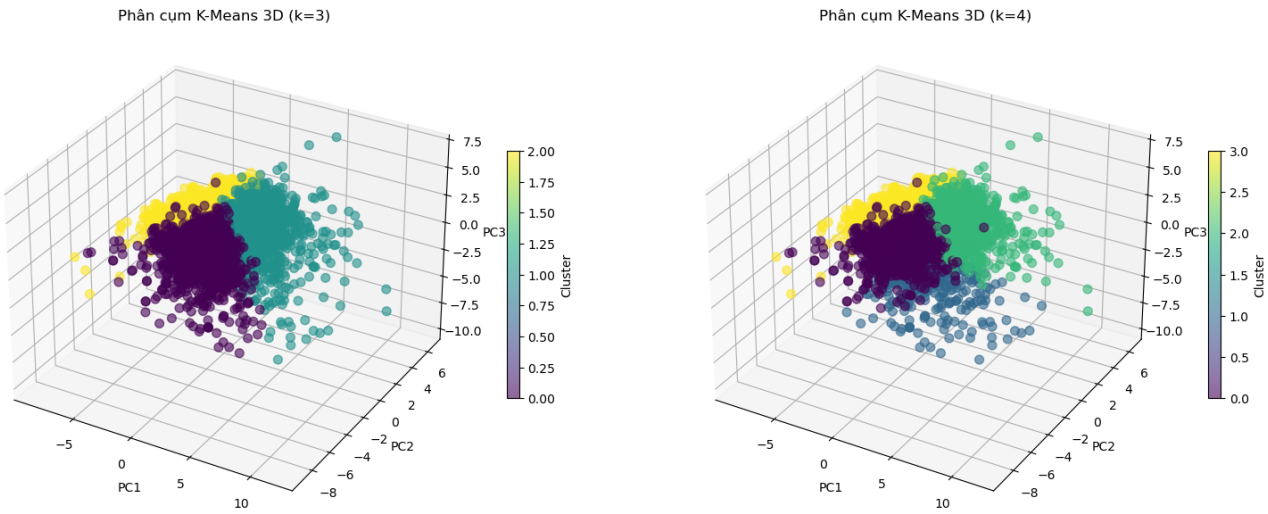
# Biểu đồ tỷ lệ phương sai được giải thích
analyzer.plot_pca_variance()
```

IV.4. So sánh phân cụm K=3 và K=4

Việc lựa chọn số lượng cụm K là một quyết định quan trọng. Dựa trên biểu đồ Elbow và Silhouette score, ta cân nhắc giữa K=3 và K=4. Dưới đây là sự so sánh trực quan kết quả phân cụm trên không gian PCA 2D và 3D.



Hình 11: So sánh phân cụm trên không gian 2D. Bên trái là K=3, bên phải là K=4.



Hình 12: So sánh phân cụm trên không gian 3D. K=4 cho thấy sự tách biệt rõ ràng hơn ở vùng trung tâm.

Quan sát hình ảnh trực quan, ta thấy sự khác biệt rõ rệt:
Với K=3, dữ liệu được chia thành 3 vùng lớn:

- Vùng màu vàng bên trái: Tách biệt khá rõ, đại diện cho nhóm khách hàng có hành vi mua sắm đặc thù (thường là nhóm chi tiêu thấp hoặc ít hoạt động).
- Vùng màu xanh ngọc ở trên: Tập trung mật độ cao.
- Vùng màu tím ở dưới: Phân bố trải rộng hơn.

Với K=4, cấu trúc dữ liệu trở nên chi tiết hơn:

- Vùng màu vàng bên trái vẫn giữ nguyên sự ổn định, cho thấy đây là một nhóm khách hàng rất đặc trưng và tách biệt.

- Sự thay đổi lớn nhất nằm ở khối dữ liệu bên phải. Vùng giao thoa giữa nhóm xanh ngọc và tím ở K=3 nay đã được tách ra thành một cụm mới (màu xanh dương nhạt trong hình 3D hoặc màu xanh đậm hơn trong hình 2D).
- Điều này cho thấy K=4 giúp phát hiện ra một nhóm khách hàng trung gian hoặc nhóm chuyển đổi mà K=3 đã gộp chung vào các nhóm lớn. Về mặt kinh doanh, việc tách nhóm này ra giúp ta có chiến lược tiếp cận tinh tế hơn, tránh đánh đồng những khách hàng có hành vi "lưng chừng" với những khách hàng điển hình của nhóm lớn.

Dưới đây là mã nguồn để thực hiện phân cụm và vẽ các biểu đồ trên:

Thực hiện K-Means và trực quan hóa

```
# Áp dụng K-Means với k=3 và k=4
cluster_results = analyzer.apply_kmeans([3, 4])

# Trực quan hóa clusters trong không gian PCA 2D
analyzer.plot_clusters_pca([3, 4])

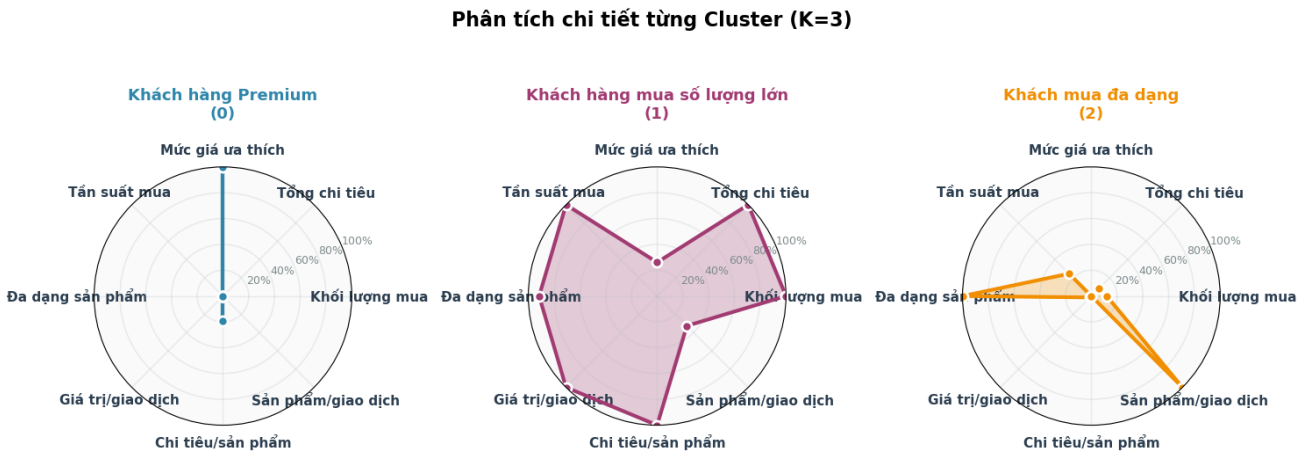
# Trực quan hóa clusters trong không gian PCA 3D
analyzer.plot_clusters_pca_3d([3, 4])
```

IV.5. Phân tích chuyên sâu biểu đồ Radar

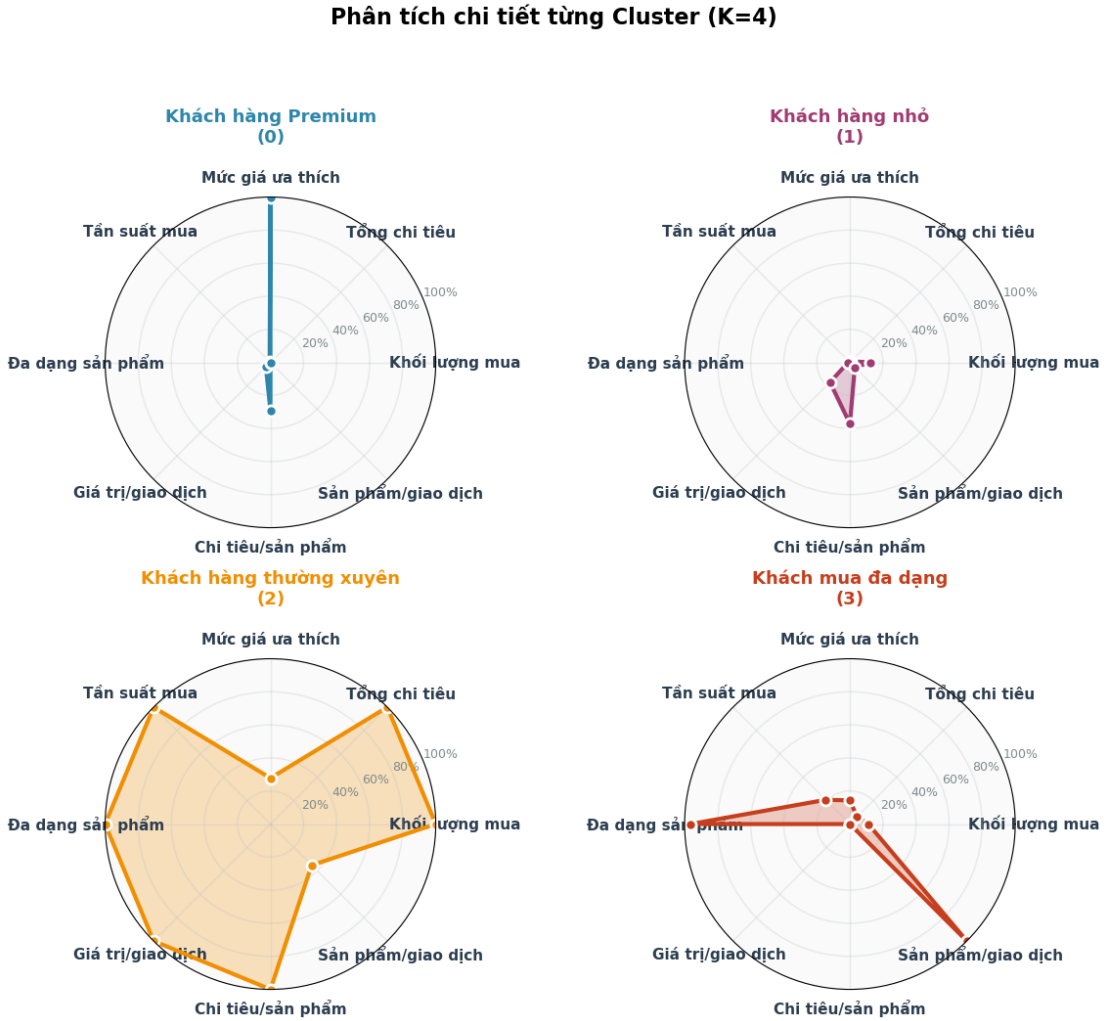
Biểu đồ Radar (hay Spider Chart) là công cụ đắc lực để trực quan hóa "hồ sơ" (profile) của từng nhóm khách hàng trên đa chiều dữ liệu. Thay vì chỉ nhìn vào các con số thống kê khô khan, biểu đồ Radar giúp ta nhận diện ngay lập tức hình dáng hành vi của từng cụm.

IV.5.1. So sánh cấu trúc phân cụm: K=3 và K=4

Trong quá trình thử nghiệm, ta nhận thấy sự chuyển dịch thú vị khi tăng số lượng cụm từ $K = 3$ lên $K = 4$. Việc này không chỉ đơn thuần là chia nhỏ dữ liệu, mà còn giúp tách biệt các nhóm hành vi bị gộp chung hay còn gọi là under-segmented.



(a) Kết quả phân cụm với K=3: Các nhóm còn khá tổng quát.



(b) Kết quả phân cụm với K=4: Nhóm "Khách hàng nhỏ" và "Thường xuyên" tách biệt rõ hơn.

Hình 13: So sánh hồ sơ khách hàng trên biểu đồ Radar. Việc tăng số cụm từ K=3 lên K=4 giúp nhận diện chi tiết hơn các hành vi mua sắm của người tiêu dùng.

Dựa trên kết quả phân tích định lượng, ta có các quan sát quan trọng sau:

1. **Sự ổn định của nhóm premium (Cluster 0):** Dù ở $K = 3$ hay $K = 4$, nhóm này vẫn giữ nguyên đặc tính với mức giá trung bình (UnitPrice) cao vượt trội (6.35 so với mức trung bình $2.6 - 3.5$). Đây là nhóm khách hàng High-margin (biên lợi nhuận cao), ít nhạy cảm về giá nhưng số lượng mua chỉ ở mức trung bình.

2. **Sự phân tách của nhóm mua số lượng lớn:** Tại $K = 3$, Cluster 1 chiếm tới 38.6% dữ liệu, gộp chung cả khách hàng doanh nghiệp lớn và các khách hàng mua sỉ nhỏ lẻ. Khi chuyển sang $K = 4$, nhóm này được tách thành hai phân khúc rõ ràng hơn:

   - **Cluster 1 (Mới - 16.5%):** Nhóm khách hàng nhỏ, mua ít hơn, có thể là các hộ kinh doanh bán lẻ.
   - **Cluster 2 (Mới - 33.6%):** Nhóm khách hàng mua sỉ thực thụ với tần suất và số lượng cực lớn.

3. **Nhóm khám phá (Cluster 3):** Đặc trưng bởi sự cân bằng trong đa dạng danh mục sản phẩm nhưng giá trị đơn hàng thấp. Đây là nhóm khách hàng đang trong giai đoạn tìm hiểu sản phẩm.

Việc lựa chọn $K = 4$ mang lại tính Actionability (khả năng hành động) cao hơn cho doanh nghiệp, cho phép thiết kế các chiến lược khuyến mãi riêng biệt cho nhóm số lượng lớn lớn và nhóm hộ kinh doanh nhỏ, thay vì áp dụng chung một chính sách bán sỉ chung chung.

IV.6. Quy trình định danh khách hàng với ChatGPT

Việc gán nhãn cho các cụm số vô tri (Cluster 0, 1, 2...) thành các chân dung khách hàng có hồn là bước quan trọng để chuyển đổi từ kỹ thuật sang giá trị trong kinh doanh. Đây là lúc chúng ta kết hợp dữ liệu định lượng với "trực giác" của các mô hình ngôn ngữ lớn (LLMs). Thay vì đưa toàn bộ dữ liệu thô, chúng ta cần một bảng tóm tắt các chỉ số trung bình để ChatGPT có thể hiểu dễ dàng hơn bức tranh tổng quát của đề bài. Ta sử dụng code sau để tạo ra bảng markdown chứa các dòng dữ liệu đại diện cho toàn bộ một cluster:

Tạo bảng thống kê trung bình

```
cluster_results = analyzer.apply_kmeans([3, 4])

display(cluster_means_3.round(2).style.background_gradient(cmap='viridis', axis=0))
display(cluster_means_4.round(2).style.background_gradient(cmap='viridis', axis=0))
```

Sau khi có được các dòng dữ liệu tiêu biểu nói trên, ta sẽ sử dụng một prompt đơn giản để có thể yêu cầu mô hình LLMs cho ta tên của từng cụm. Một prompt hiệu quả không chỉ đưa dữ liệu, mà phải cung cấp luật và ngữ cảnh cần thiết cho mô hình. Dưới đây là mẫu Prompt chi tiết bạn có thể copy trực tiếp vào ChatGPT/Claude:

Prompt phân tích hồ sơ khách hàng

Role: Bạn là giám đốc marketing và chuyên gia phân tích dữ liệu của một chuỗi bán lẻ online tại UK.
Context: Tôi vừa thực hiện thuật toán K-Means Clustering và chia khách hàng thành 4 nhóm. Dưới đây là định nghĩa các biến: ...
Data: [DÁN BẢNG KẾT QUẢ TỪ BƯỚC TRÊN VÀO ĐÂY]
Task: Hãy phân tích từng cụm (Cluster) và thực hiện các yêu cầu sau:

1. **Đặt tên (Naming):** Đặt 1 tên tiếng Anh chuyên nghiệp và 1 tên tiếng Việt dễ nhớ (Ví dụ: "Big Spenders", "Lost Customers").
2. **Mô tả (Persona):** Mô tả ngắn gọn hành vi của nhóm này trong 1 câu.
3. **Chiến lược (Action):** Đề xuất 1 hành động marketing cụ thể (Ví dụ: gửi email, upsell, kích cầu...).

Hãy trình bày kết quả dưới dạng bảng Markdown.

AI sẽ cung cấp một góc nhìn tham khảo rất tốt. Tuy nhiên, chúng ta cần đối chiếu lại với biểu đồ Radar Chart nói trên để đảm bảo tên gọi phản ánh đúng thực tế của mẫu dữ liệu, tránh trường hợp ảo giác của mô hình.

Ví dụ kết quả sau khi tinh chỉnh:

- **Cluster 0 - The Whales:** Chi tiêu cực lớn, mua thường xuyên. → Chiến lược: Chăm sóc VIP 1-1, mời tham gia sự kiện lớn.
- **Cluster 2 - Hibernating:** Đã từng mua nhưng lâu không quay lại. → Chiến lược: Gửi email "We miss you" kèm mã giảm giá. Tạo ra chương trình tri ân khách hàng.
- **Cluster 3 - Small Sales:** Nhóm khách hàng chi tiêu nhỏ nhưng mua nhiều loại mặt hàng. → Chiến lược: Giới thiệu nhiều mẫu mặt hàng cho nhóm này, tạo ra catalog để họ có thể dễ theo dõi những mặt hàng mới tốt hơn.

V. Các hướng cải tiến

Mặc dù mô hình K-Means hiện tại đã mang lại những kết quả khả quan trong việc định hình chân dung khách hàng, phương pháp này vẫn tồn tại một số hạn chế như giả định các cụm có dạng hình cầu lồi và kích thước tương đồng. Để nâng cao chất lượng phân khúc và khai thác sâu hơn dữ liệu, ta có thể cân nhắc các hướng tiếp cận nâng cao sau:

1. **Giảm chiều dữ liệu phi tuyến tính:** PCA là thuật toán tuyến tính, có thể bỏ sót các cấu trúc dữ liệu phức tạp. Ta có thể thử nghiệm với t-SNE hoặc UMAP. Các thuật toán này bảo toàn cấu trúc cục bộ tốt hơn, giúp việc phân tách các cụm trở nên rõ ràng hơn trong không gian thấp chiều, đặc biệt khi dữ liệu có tính phi tuyến cao.

Minh họa sử dụng UMAP

```
import umap

# Khởi tạo UMAP reducer
reducer = umap.UMAP(
    n_neighbors=15,
    min_dist=0.1,
    metric='euclidean'
)

# Giảm chiều dữ liệu xuống 2D
embedding = reducer.fit_transform(df_scaled)
```

2. **Phân cụm dựa trên mật độ (Density-based Clustering):** K-Means buộc phải gán mọi điểm dữ liệu vào một cụm, ngay cả khi đó là nhiễu. DBSCAN hoặc HDBSCAN là những lựa chọn thay thế tốt, cho phép phát hiện các cụm có hình dạng bất kỳ và tự động loại bỏ nhiễu, giúp mô hình bền vững hơn trước các dữ liệu bất thường.

3. **Tích hợp thông tin sản phẩm:** Hiện tại, mô hình chủ yếu dựa trên hành vi giao dịch (RFM). Một hướng đi tiềm năng là sử dụng kỹ thuật Xử lý ngôn ngữ tự nhiên (NLP) như TF-IDF hoặc Word2Vec để phân tích mô tả sản phẩm trong lịch sử mua hàng. Điều này giúp gom nhóm khách hàng dựa trên "gu" thẩm mỹ hoặc nhu cầu sử dụng thực tế (ví dụ: nhóm thích đồ trang trí cổ điển so với nhóm thích đồ gia dụng hiện đại), thay vì chỉ dựa trên số tiền họ chi trả.

VI. Câu hỏi trắc nghiệm

1. Đâu là mục tiêu cốt lõi của việc "Phân khúc khách hàng" so với tiếp thị đại trà?
   (*a*) Giảm thiểu tối đa chi phí vận hành hệ thống IT của doanh nghiệp.
   (*b*) Gửi cùng một email quảng cáo cho tất cả mọi người để tiết kiệm thời gian.
   (*c*) Tối ưu hóa Marketing, giữ chân khách hàng và phân bổ nguồn lực hiệu quả.
   (*d*) Loại bỏ hoàn toàn sự cần thiết của các nhân viên chăm sóc khách hàng.

2. Tại sao thuật toán K-Means Clustering được đánh giá cao hơn phương pháp phân loại thủ công trong bối cảnh Big Data?
   (*a*) Vì nó phụ thuộc nhiều vào cảm tính của người phân loại để đưa ra quyết định nhân văn hơn.
   (*b*) Vì nó có khả năng xử lý tốt dữ liệu đa chiều, tính khách quan cao và tốc độ xử lý nhanh.
   (*c*) Vì nó chỉ hoạt động tốt trên các tập dữ liệu nhỏ dưới 100 dòng.
   (*d*) Vì nó không đòi hỏi dữ liệu đầu vào phải được làm sạch hay chuẩn hóa.

3. Trong bước làm sạch dữ liệu của dự án này, các hóa đơn bắt đầu bằng ký tự nào sẽ bị loại bỏ?
   (*a*) Ký tự 'A' (Approved).
   (*b*) Ký tự 'R' (Return).
   (*c*) Ký tự 'C' (Cancelled).
   (*d*) Ký tự 'F' (Failed).

4. Tại sao mô hình RFM truyền thống (Recency, Frequency, Monetary) lại được cho là có hạn chế và cần được mở rộng thêm các features khác?
   (*a*) Vì RFM quá phức tạp để tính toán trên máy tính cá nhân thông thường.
   (*b*) Vì RFM thiếu chiều sâu về độ đa dạng sản phẩm, hành vi trong từng giao dịch và độ nhạy với giá.
   (*c*) Vì RFM chỉ áp dụng được cho các cửa hàng vật lý, không dùng được cho online.
   (*d*) Vì các chỉ số RFM không thể trực quan hóa được trên biểu đồ.

5. Mục đích chính của việc áp dụng phép biến đổi **Box-Cox** lên dữ liệu trước khi đưa vào mô hình K-Means là gì?
   (*a*) Để loại bỏ các giá trị thiếu (missing values) trong dữ liệu.
   (*b*) Để chuyển đổi dữ liệu dạng chữ (string) sang dạng số (numeric).
   (*c*) Để xử lý vấn đề dữ liệu bị lệch phải (right-skewness) và đưa về dạng gần phân phối chuẩn.
   (*d*) Để tăng số lượng dòng dữ liệu lên gấp đôi nhằm huấn luyện tốt hơn.

6. Tại sao trước khi áp dụng hàm `boxcox`, ta cần thực hiện phép tính $x + 1$ trên các giá trị dữ liệu?

(*a*) Để đảm bảo dữ liệu luôn dương tuyệt đối, do toán học của Box-Cox yêu cầu đầu vào dương.

(*b*) Để làm tròn số liệu doanh thu cho dễ nhìn hơn.

(*c*) Để tạo ra sự nhiễu ngẫu nhiên giúp mô hình không bị overfitting.

(*d*) Để chuyển đổi đơn vị tiền tệ từ Bảng Anh sang USD.

7. Hai phương pháp nào được sử dụng trong bài để xác định số cụm K tối ưu?

   (*a*) Random Forest và Decision Tree.

   (*b*) Elbow Method và Silhouette Score.

   (*c*) Gradient Descent và Backpropagation.

   (*d*) Mean Squared Error và R-squared.

8. Khi so sánh kết quả phân cụm giữa $K = 3$ và $K = 4$, sự khác biệt lớn nhất mang lại tính hành động cao hơn là gì?

   (*a*) Nhóm khách hàng VIP (Whales) bị biến mất hoàn toàn.

   (*b*) Nhóm mua số lượng lớn (vốn gộp chung ở K=3) được tách thành hai nhóm: hộ kinh doanh nhỏ và nhà bán sỉ thực thụ.

   (*c*) Tất cả các nhóm đều bị trộn lẫn vào nhau khiến việc phân biệt trở nên khó khăn hơn.

   (*d*) Nhóm khách hàng vãng lai chiếm 90% dữ liệu.

9. Biểu đồ nào được sử dụng để trực quan hóa "hồ sơ" (profile) hành vi của từng nhóm khách hàng trên đa chiều dữ liệu?

   (*a*) Biểu đồ Pie Chart.

   (*b*) Biểu đồ Radar (Spider Chart).

   (*c*) Biểu đồ Line Chart theo thời gian.

   (*d*) Biểu đồ Gantt Chart.

10. Để khắc phục hạn chế của K-Means (giả định cụm hình cầu) và xử lý dữ liệu phi tuyến tính tốt hơn, bài viết đề xuất hướng cải tiến nào?

    (*a*) Quay lại sử dụng phương pháp phân loại thủ công bằng Excel.

    (*b*) Sử dụng thuật toán giảm chiều dữ liệu t-SNE/UMAP và phân cụm dựa trên mật độ (DBSCAN).

    (*c*) Chỉ sử dụng duy nhất chỉ số Monetary để phân nhóm.

    (*d*) Tăng số lượng cụm K lên 100 để chi tiết hóa tối đa.

VII. Tài liệu tham khảo
Phụ lục

1. **Code:** Các file code được đề cập trong bài có thể được tải tại đây.
2. **Q&A:** Bạn có thể đặt thêm câu hỏi về nội dung bài đọc trong group Facebook hỏi đáp tại đây. Tất cả câu hỏi sẽ được trả lời trong vòng 3-4 tiếng.



Hình 14: Hình ảnh group facebook AIO Q&A.